

Дистрибутивная семантика

Векторное представление слова

Екатерина Черняк

Факультет компьютерных наук НИУ ВШЭ

February 15, 2018

- 1 Введение
- 2 Счетные и нейронные модели представления слова
 - Факторизация матрицы терм-контекст
 - Word2Vec
 - Word2Vec как факторизация матрицы sPMI
- 3 Использование представлений слова
- 4 Другие модели
 - Word2Vec-f
 - Doc2Vec
 - GloVe
 - FastText
 - AdaGram
- 5 Другое
 - Двуязычные представления слов
 - HistWords
 - Составления предметных словарей эмоционально-окрашенных слов

1 Введение

2 Счетные и нейронные модели представления слова

- Факторизация матрицы терм-контекст
- Word2Vec
- Word2Vec как факторизация матрицы sPMI

3 Использование представлений слова

4 Другие модели

- Word2Vec-f
- Doc2Vec
- GloVe
- FastText
- AdaGram

5 Другое

- Двуязычные представления слов
- HistWords
- Составления предметных словарей эмоционально-окрашенных слов

Представление слова

Word representation [TRB10]

A *word representation* is a mathematical object associated with each word, often a vector. Each dimension's value corresponds to a feature and might even have a semantic or grammatical interpretation, so we call it a word feature.

Word embedding

A *word embedding* is a vector in a low dimensional space, which represents each word.

Примеры (<http://rusvectors.org>, [KK16])

мороз_NOUN

Выберите модель:

☒ Новостной корпус ☐ Araneum fastText ☐ Araneum Maximum ☐ НКРЯ и Wikipedia ☐ НКРЯ

Показывать только:

☐ Наречия ☐ Прилагательные ☐ Имена собственные ☐ Глаголы ☐ Существительные ☒ Все части речи ☐ Часть речи запроса

Найти похожие слова!

Семантические аналоги для **мороз** (ALL)

Новостной корпус

1. **холод** 0.59
2. **стужа** 0.59
3. **жара** 0.55
4. **двадцатиградусный** 0.52
5. **тридцатиградусный** 0.51
6. **трескучий** 0.49
7. **вьюга** 0.48
8. **градусный** 0.48
9. **морозец** 0.47
10. **мазай** 0.46



Примеры (<http://rusvectors.org>, [KK16])



Новостной корпус

1. лето 0.44
2. зной 0.41
3. весна 0.38
4. малоснежный 0.38
5. осень 0.37



Обозначения

- $w \in V_W$ – слова, всего слов $|V_W|$
- $c \in V_C$ – контексты, всего контекстов $|V_C|$
- $\#(w, c)$ – сколько раз слово w встретилось в контексте c
- $(w, c) \in D$ – наблюдаемые пары (слово, контекст), всего пар $|D|$
 $\sum_w \sum_c \#(w, c) = |D|$
- $E \in \mathbb{R}^{|V| \times d}$ – матрица эмбедингов
- d – размерность эмбединга, $d \ll |V_W|$

Дистрибутивная семантика

Смысл слова [L. Wittgenstein]

Die Bedeutung eines Wortes liegt in seinem Gebrauch.

Distributional hypothesis [J.R.Firth]

You shall know a word by the company it keeps!

Векторная модель: матрица слово-контекст M

$$M_{[i,j]} = f(w_i, c_j)$$

	c_1	c_2	...	$c_{ V_C }$
w_1	f_{11}	f_{12}		$f_{1 V_C }$
w_2	f_{21}	f_{22}		$f_{2 V_C }$
...				
$w_{ V_W }$	$f_{ V_W 1}$	$f_{ V_W 2}$		$f_{ V_W V_C }$

Векторная модель: матрица слово-контекст $M \in \mathbb{R}^{V_w \times V_c}$

$$M_{[i,j]} = f(w_i, c_j)$$

Как определить $f(w_i, c_j)$?

- $\#(w, v)$
- $P(w, c) = \frac{\#(w, c)}{|D|}$
- $\text{PMI}(w, c) = \log \frac{\#(w, c)|D|}{\#(w)\#(c)}$
- $\text{PPMI}(w, c) = \max(\text{PMI}(w, c), 0)$

Как определить $f(w_i, c_j)$?

Векторная модель: матрица слово-контекст $M \in \mathbb{R}^{V_w \times V_c}$

$$M_{[i,j]} = f(w_i, c_j)$$

$$\#(w, v) \text{ или } P(w, c) = \frac{\#(w, v)}{|D|}$$

	the	a	...	cute
w_1	f_{11}	f_{12}		$f_{1 V_c }$
cat	f_{21}	f_{22}		$f_{2 V_c }$
...				
$w_{ V_w }$	$f_{ V_w 1}$	$f_{ V_w 2}$		$f_{ V_w V_c }$

Как определить $f(w_i, c_j)$?

Векторная модель: матрица слово-контекст M

$$M_{[i,j]} = f(w_i, c_j)$$

$$\text{PMI}(w, c) = \log \frac{\#(w, c) |D|}{\#(w) \#(c)}$$

	the	a	...	cute
w_1	f_{11}	f_{12}		$f_{1 V_C }$
cat	f_{21}	f_{22}		$f_{2 V_C }$
...				
$w_{ V_W }$	$f_{ V_W 1}$	$f_{ V_W 2}$		$f_{ V_W V_C }$

$$\text{PMI}(w, c) = |\#(w, c) = 0| = \log 0 = -\infty \Rightarrow$$

$$\text{PPMI}(w, c) = \max(\text{PMI}(w, c), 0)$$

Оценка близости между словами

- Косинусная мера близости:

$$\cos(u, v) = \frac{u \cdot v}{\|u\|_2 \|v\|_2} = \frac{\sum_i u_i v_i}{\sqrt{\sum_i u_i^2} \sqrt{\sum_i v_i^2}}$$

- Мера Жаккара:

$$jc(u, i) = \frac{\sum_i \min(u_i, v_i)}{\sum_i \max(u_i, v_i)}$$

1 Введение

2 Счетные и нейронные модели представления слова

- Факторизация матрицы терм-контекст
- Word2Vec
- Word2Vec как факторизация матрицы sPMI

3 Использование представлений слова

4 Другие модели

- Word2Vec-f
- Doc2Vec
- GloVe
- FastText
- AdaGram

5 Другое


- Двуязычные представления слов
- HistWords
- Составления предметных словарей эмоционально-окрашенных слов

Факторизация матрицы терм-контекст

Снижение размерности матрицы слово-контекст $M \in \mathbb{R}^{V_w \times V_c}$:

$$M' = W \times V^T, W \in \mathbb{R}^{V_w \times d}, V \in \mathbb{R}^{V_c \times d}$$


M' – лучшее приближение ранга d к M по L_2 .



Факторизация матрицы терм-контекст

Сингулярное разложение матрицы слово-контекст $M \in \mathbb{R}^{V_w \times V_c}$:


$$M = U \Sigma D^T$$



Факторизация матрицы терм-контекст

Аппроксимация ранга d матрицы слово-контекст $M \in \mathbb{R}^{V_W \times V_C}$:

$$M'_d = U_d \Sigma_d D_d^\top$$



Искомое разложение M :

$$W = U_d \sqrt{\Sigma_d}, V^\top = \sqrt{\Sigma_d} D_d^\top$$

Примеры

- Тьюториал М. Baroni
- Курс А. Copestake и А. Herbelot

1 Введение

2 Счетные и нейронные модели представления слова

- Факторизация матрицы терм-контекст
- Word2Vec
- Word2Vec как факторизация матрицы sPMI

3 Использование представлений слова

4 Другие модели

- Word2Vec-f
- Doc2Vec
- GloVe
- FastText
- AdaGram

5 Другое

- Двуязычные представления слов
- HistWords
- Составления предметных словарей эмоционально-окрашенных слов

Word2Vec [MCCD13]

1 Две архитектуры:

- ▶ Continuous bag-of-words model (CBOW)
- ▶ skip-gram

2 Два критерия оптимизации:

- ▶ Hierarchical softmax
- ▶ Negative-sampling: для каждой пары $(w, c) \in D$ найти k слов, таких что $(w_k, c) \in D$

D – множество наблюдаемых пар слово-контекст

\bar{D} – множество ненаблюдаемых пар слово-контекст


Вероятность $(w, c) \in D$: $P(D = 1|w, c) = \frac{1}{1+e^{-s(w,c)}}$

Оптимизационная задача:

$$L(\Theta, D, \bar{D}) = \sum_{(w,c) \in D} P(D = 1|w, c) + \sum_{(w,c) \in \bar{D}} P(D = 0|w, c)$$

Continuous bag-of-words model (CBOW) [MCCD13]


- Входной слой: контекст слова (+, - $\frac{k}{2}$ слова слева и справа)
- Слой проекции: линейный
- Выходной слой: вектор слова



$$P(D = 1|w, c_{1:k}) = \frac{1}{1 + e^{-(w \cdot c_1 + w \cdot c_2 + \dots + w \cdot c_k)}}, c = \sum_{i=1}^k c_i$$

skip-gram [MCCD13]

- Обратная задача: предсказание векторов контекста по данному слову
- Выходной слой: вектор слов
- Все контексты независимы:
 $(w, c_1), \dots, (w, c_k)$



$$P(D = 1|w, c_i) = \frac{1}{1 + e^{-(w \cdot c_i)}}$$

$$P(D = 1|w, c_{1:k}) = \prod_{i=1}^k P(D = 1|w, c_i) = \prod_{i=1}^k \frac{1}{1 + e^{-(w \cdot c_i)}}$$

1

Введение

2

Счетные и нейронные модели представления слова

- Факторизация матрицы терм-контекст
- Word2Vec
- Word2Vec как факторизация матрицы sPMI

3

Использование представлений слова

4

Другие модели

- Word2Vec-f
- Doc2Vec
- GloVe
- FastText
- AdaGram

5

Другое

- Двуязычные представления слов
- HistWords
- Составления предметных словарей эмоционально-окрашенных слов

Дистрибутивная семантика и Word2Vec [LG14b]

Результат Word2Vec: две матрицы, $E^W \in \mathbb{R}^{V_W \times d}$ и $E^C \in \mathbb{R}^{V_C \times d}$

Пусть $M' = E^W \times E^C$.

Связь исходной матрицы слово-контекст M и M' :

$$w \cdot c = M'_{[w,c]} = \text{PMI}(w, c) - \log k,$$

где k – число отрицательных контекстов

- 1 Введение
- 2 Счетные и нейронные модели представления слова
 - Факторизация матрицы терм-контекст
 - Word2Vec
 - Word2Vec как факторизация матрицы sPMI
- 3 Использование представлений слова
- 4 Другие модели
 - Word2Vec-f
 - Doc2Vec
 - GloVe
 - FastText
 - AdaGram
- 5 Другое
 - Двуязычные представления слов
 - HistWords
 - Составления предметных словарей эмоционально-окрашенных слов

Сравнение моделей эмбедингов [SLMJ15]

① Внутренние (intrinsic) задачи

- ▶ Определение похожих слов
- ▶ Определение аналогий
- ▶ Категоризация слов
- ▶ Определение лишнего слова
- ▶ Определение объектов глаголов

② Внешние (extrinsic) задачи

- ▶ Классификация текстов
- ▶ Извлечение именованных сущностей
- ▶ Расширение запроса

Результаты зависят от использованного корпуса для обучения, гиперпараметров обучения, корпуса для тестирования. Невозможно определить модель эмбедингов, превосходящую остальные.

- 1 Введение
- 2 Счетные и нейронные модели представления слова
 - Факторизация матрицы терм-контекст
 - Word2Vec
 - Word2Vec как факторизация матрицы sPMI
- 3 Использование представлений слова
- 4 Другие модели
 - Word2Vec-f
 - Doc2Vec
 - GloVe
 - FastText
 - AdaGram
- 5 Другое
 - Двуязычные представления слов
 - HistWords
 - Составления предметных словарей эмоционально-окрашенных слов

Word2Vec-f (dependency embeddings) [LG14a]

Выбор контекста: синтаксически зависимые слова.

Результат: функциональные зависимости.

Target Word	BoW5	BoW2	Deps
batman	nightwing aquaman catwoman superman manhunter	superman superboy aquaman catwoman batgirl	superman superboy supergirl catwoman aquaman
hogwarts	dumbledore hallows half-blood malfoy snape	evernight sunnydale garderobe blandings collinwood	sunnydale collinwood calarts greendale millfield
turing	nondeterministic non-deterministic computability deterministic finite-state	non-deterministic finite-state nondeterministic buchi primality	pauling hotelling heting lessing hamming
florida	gainesville fla jacksonville tampa lauderdale	fla alabama gainesville tallahassee texas	texas louisiana georgia california carolina
object-oriented	aspect-oriented smalltalk event-driven prolog domain-specific	aspect-oriented event-driven objective-c dataflow 4gl	event-driven domain-specific rule-based data-driven human-centered
dancing	singing dance dances dancers tap-dancing	singing dance dances breakdancing clowning	singing rapping breakdancing miming busking

Насколько похожи два предложения (абзаца)? [LM14]


Как найти вектор-предложения (абзаца) ?

- 1 Усреднить вектора слов, входящих в каждое предложение (с *tf* – *idf* весами)
- 2 Doc2vec: что word2vec, только для предложений (абзацев)

Classifier

Average/Concatenate

Paragraph Matrix----->



Global Vectors [PSM14]

	$x = \text{solid}$	$x = \text{gas}$	$x = \text{water}$	$x = \text{random}$
$p(x \text{ice})$	large	small	large	small
$p(x \text{steam})$	small	large	large	small
$p(x \text{ice})/p(x \text{steam})$	large	small	1	1

$$w \cdot c + b_{|w|} + b_{|c|} = \log(w, c) \quad \forall (w, c) \in D,$$

$b_{|w|}, b_{|c|}$ – обучаемые сдвиги для слов и контекстов

FastText [BGJM16]

Слово w представляем символьными n -граммами:

$n = 3$, $G_{where} = _wh, whe, her, re_ , _where_$

$sim_{w2v}(u, v) = \langle u, v \rangle$

$sim_{ft}(u, v) = \sum_{e \in G_u} \sum_{g \in G_v} \langle e, v \rangle$


AdaGram [BKOV16]

Находит k смыслов слова.
Демо

- 1 Введение
- 2 Счетные и нейронные модели представления слова
 - Факторизация матрицы терм-контекст
 - Word2Vec
 - Word2Vec как факторизация матрицы sPMI
- 3 Использование представлений слова
- 4 Другие модели
 - Word2Vec-f
 - Doc2Vec
 - GloVe
 - FastText
 - AdaGram
- 5 Другое
 - Двуязычные представления слов
 - HistWords
 - Составления предметных словарей эмоционально-окрашенных слов


Двуязычные эмбе́ддинги [ZSCM13]

Дан (выровненный) параллельный корпус. Контекст слова: перевод
этого слова на другой язык.




Двуязычные эмбединги [CLR⁺17]

- 1 Дано два невыровненных пространства слов
- 2 Adversarial learning для определения матрицы поворота W
- 3 Прокрустово преобразование для уточнения W
- 4 k – NN -подобный метод для окончательного выравнивания




Диахронические эмбединги: Прокрустово преобразование для поворота пространства эмбедингов из периода $t - 1$ в t




Составления предметных словарей эмоционально-окрашенных слов [HCLJ16]

- 1 Граф близости на словах
- 2 Случайное блуждание для распространения метки






a. Run random walks from seed words.



b. Assign polarity scores based on frequency of random walk visits.

Источники I

-  Piotr Bojanowski, Edouard Grave, Armand Joulin, and Tomas Mikolov, *Enriching word vectors with subword information*, arXiv preprint arXiv:1607.04606 (2016).
-  Sergey Bartunov, Dmitry Kondrashkin, Anton Osokin, and Dmitry Vetrov, *Breaking sticks and ambiguities with adaptive skip-gram*, Artificial Intelligence and Statistics, 2016, pp. 130–138.
-  Alexis Conneau, Guillaume Lample, Marc'Aurelio Ranzato, Ludovic Denoyer, and Hervé Jégou, *Word translation without parallel data*, arXiv preprint arXiv:1710.04087 (2017).
-  William L Hamilton, Kevin Clark, Jure Leskovec, and Dan Jurafsky, *Inducing domain-specific sentiment lexicons from unlabeled corpora*, Proceedings of the Conference on Empirical Methods in Natural Language Processing. Conference on Empirical Methods in Natural Language Processing, vol. 2016, NIH Public Access, 2016, p. 595.

Источники II



William L Hamilton, Jure Leskovec, and Dan Jurafsky, *Diachronic word embeddings reveal statistical laws of semantic change*, arXiv preprint arXiv:1605.09096 (2016).



Andrey Kutuzov and Elizaveta Kuzmenko, *Webvectors: a toolkit for building web interfaces for vector semantic models*, International Conference on Analysis of Images, Social Networks and Texts, Springer, 2016, pp. 155–161.







Omer Levy and Yoav Goldberg, *Dependency-based word embeddings*, Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), vol. 2, 2014, pp. 302–308.



_____, *Neural word embedding as implicit matrix factorization*, Advances in neural information processing systems, 2014, pp. 2177–2185.

Источники III

-  Quoc Le and Tomas Mikolov, *Distributed representations of sentences and documents*, International Conference on Machine Learning, 2014, pp. 1188–1196.
-  Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean, *Efficient estimation of word representations in vector space*, arXiv preprint arXiv:1301.3781 (2013).
-  Jeffrey Pennington, Richard Socher, and Christopher Manning, *Glove: Global vectors for word representation*, Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP), 2014, pp. 1532–1543.
-  Tobias Schnabel, Igor Labutov, David Mimno, and Thorsten Joachims, *Evaluation methods for unsupervised word embeddings*, Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 2015, pp. 298–307.

Источники IV



Joseph Turian, Lev Ratinov, and Yoshua Bengio, *Word representations: a simple and general method for semi-supervised learning*, Proceedings of the 48th annual meeting of the association for computational linguistics, Association for Computational Linguistics, 2010, pp. 384–394.



Will Y Zou, Richard Socher, Daniel Cer, and Christopher D Manning, *Bilingual word embeddings for phrase-based machine translation*, Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing, 2013, pp. 1393–1398.